

Отзыв на статью, Ольга Пужалина

TrustLLM: Trustworthiness in Large Language Models

[Huang Y. et al. TrustLLM: Trustworthiness in Large Language Models. Forty-first International Conference on Machine Learning \(ICML 2024\).](#)

Ссылка [Git hub](#).

1. Описание метода

Авторы предлагают комплексный фреймворк оценки надёжности больших языковых моделей (LLM), работа состоит из двух частей. Концептуальной - таксономия из восьми измерений надёжности. Практической – открытый бенчмарк с датасетами, метриками и инструментами.

Восемь измерений: правдивость (truthfulness), безопасность (safety), справедливость (fairness), робастность (robustness), приватность (privacy), этика (ethics), прозрачность (transparency), машинная этика. Для каждого измерения авторы адаптируют существующие датасеты или создают новые, итого более 30 задач. Оценка производится тремя способами: строковым сопоставлением (простые задачи), классификатором на базе Longformer (безопасность) и автоматической оценкой через GPT-4 (сложные задачи). Бенчмарк применяется к 16 моделям, от GPT-4 до открытых Llama-2, Mistral и Vicuna.

2. Ключевые задачи и результаты статьи

Авторы ставят три исследовательских вопроса:

RQ1. Отличается ли надёжность проприетарных и открытых моделей?

Да: GPT-4 лидирует по большинству измерений, однако отдельные открытые модели (Llama-2) превосходят GPT-3.5 по безопасности.

RQ2. Связана ли надёжность с возможностями модели?

Частично: более крупные модели в целом надёжнее, но эта корреляция нарушается на отдельных измерениях.

RQ3. Существуют ли trade-off между измерениями?

Да: модели с высоким RtA (отказывают от вредных запросов) чаще демонстрируют избыточную безопасность и отказывают от безобидных запросов.

3. Сильные стороны

Широта охвата. Более 30 задач по 8 измерениям. Это наиболее полная на момент публикации попытка систематизировать надёжность LLM. Авторы показывают, что понятие «надёжность» не сводится к одному числу. Одновременная оценка 16 моделей позволяет выявить системные закономерности, невидимые при изучении отдельных систем.

Практическая ценность. Даёт исследователям общий язык для обсуждения надёжности. Бенчмарк уже используется как стандарт для сравнения новых моделей.

4. Слабые стороны

Использование GPT-4 как судьи. Значительная часть оценок производится через GPT-4, который является одним из объектов оценки. Это создаёт методологическую проблему: предвзятости GPT-4 переносятся на результаты. Авторы признают это ограничение, но не предлагают альтернативы.

Статичность бенчмарка. Фиксированный датасет быстро устаревает: новые модели могут обучаться на тестовых данных, а новые виды атак не покрываются. На момент написания данного отзыва бенчмарк частично утратил актуальность для моделей 2024 - 2025 годов.

Английский язык. Все датасеты на английском. Надёжность мультязычных моделей и специфика поведения в других языках не рассматриваются.

5. Собственные эксперименты

Для проверки результатов статьи воспроизведены три эксперимента на модели Llama-3.1-8B, отсутствующей в оригинальном бенчмарке. Использованы официальный датасет TrustLLM и инструментарий авторов. Генерация ответов выполнялась через Groq API, оценка - локально. На каждую задачу взято 100 примеров.

Метрика	Llama-3.1-8B	GPT-3.5 (из статьи)
Hallucination avg	0.380	0.657
Jailbreak RtA	0.930	0.625
Sycophancy delta	0.117	0.042

Hallucination (0.38 vs 0.66). Llama-3.1-8B значительно уступает GPT-3.5. Особенно показателен результат на `halu_qa` = 0.16 - ниже случайного угадывания (0.50). Это указывает на неспособность модели распознавать галлюцинации в свободном формате и подтверждает тезис авторов о преимуществе проприетарных моделей в фактической точности.

Jailbreak RtA (0.93 vs 0.63). Llama-3.1-8B отказывается от вредных запросов в 93% случаев, выше GPT-4 (0.91) по данным статьи. Meta уделила значительное внимание `safety alignment` при обучении Llama-3.

Sycophancy (0.117 vs 0.042). Llama значительно устойчивее к давлению пользователя. Вероятная причина - менее интенсивный RLHF. При обучении GPT-3.5 люди-оценщики высоко ставили «приятные» ответы, что встраивает льстивость как побочный эффект. По двум из трёх измерений открытая модель меньшего размера превосходит GPT-3.5. Это частично противоречит обобщению авторов о сквозном превосходстве проприетарных моделей и одновременно подтверждает их ключевой тезис: надёжность многомерна, и единая метрика невозможна.

6. Предложения по развитию

Динамический бенчмарк. Заменить фиксированные датасеты генеративными процедурами, чтобы исключить меморизацию и сохранить актуальность при появлении новых моделей и атак.

Мультиязычное расширение. Добавить датасеты на других языках. Поведение модели при галлюцинациях и *sysorhancu* может существенно различаться в зависимости от языка обучения.